

$$p_{\theta}(x) = p(x; \theta) = p(x|\theta)$$

각각의 θ 에 대해 x 가 나올 확률이 같지는 않음

$$p_{\theta}(y|x) = p(y|x; \theta) = p(y|x, \theta)$$

각각의 θ 가 있을 때 x 가 주어졌을 때 y 가 나올 확률

MLE

$$\Theta = \{w_1, b_1, w_2, b_2, \dots\}$$

Gradient Ascent 을 통해


찾을 것

하지만 대부분의 딥러닝 프레임워크는 Gradient descent 만
사용

No problem - 1 문제 하려면 될 것

그러나 Maximization 오히려 minimization 문제로 생각

Negative log Likelihood (NLL)



$$-\sum_{i=1}^N \log p(y_i | x_i; \theta) = -\sum_{i=1}^N y_i^T \cdot \log \hat{y}_i$$

cross entropy loss

자 MLE

$p(y_i | x_i; \theta)$

→ 확률 분포 θ (D에서 weight) 에러 X가 주어졌을 때
 y 의 확률

MLE $L(\theta) =$

한번의 시행에서 사건 A가 일어날 확률로 p라 할 때, 이 시행을 n회 반복한 독립시행에서 사건 A가 r번 일어날 확률은

$$nCr p^r (1-p)^{n-r}$$

$$\left(\prod_{i=1}^N p(y_i | x_i; \theta) \right)$$

→ 해당 관찰 결과에 해당하는 확률을

여기에 x 을 +로 바꾸기 위해 data underflow 를 방지하기 위해

$$\text{Log } L(\theta) \text{ 를 Maximum likelihood 로 변환}$$
$$\sum_{i=1}^N \log P(y_i | x_i; \theta)$$

(이 식을 최대화 하는 θ 가 가능할수록 $L(\theta)$ 도 최대가 됨)

ML의 목적 $L(\theta)$ 가 가장 큰 곳의 θ 즉 $L(\theta)$ 를 미분했을 때 값이 0이 되는 θ 를 찾는 것

$$\hat{\theta} = \underset{\theta \in \Theta}{\operatorname{argmax}} \sum_{i=1}^N \log P(y_i | x_i; \theta)$$

그러나 이 식은 Gradient Ascent 를 통해 해결

$$\hat{\theta} = \underset{\theta \in \Theta}{\operatorname{argmin}} - \sum_{i=1}^N \log P(y_i | x_i; \theta) \text{로 변환}$$

\hookrightarrow Gradient descent

Model 의 결과물을 \hat{y}

X 가 파라미터 θ 를 거쳐서 나온 출력 \hat{y}
→ 포스트 프로세싱


$$p(y_i | x_i; \theta)$$

→ 학습을 통해 θ (DNN에서는 weight) 을/서 X가 주어졌을 때
y의 확률


$$\hat{y}_i = p(y_i | x_i; \theta)$$

$$-\sum_{i=1}^N \log p(y_i | x_i; \theta) = -\sum_{i=1}^N \log \hat{y}_i$$

자 여기서 softmax



각 클래스 별로 확률을 제공



one-hot vector

$$\hat{y}_i = \frac{y_i^T \cdot x}{\hat{y}_i}$$

→ i번째 1 나머지 0 해당 index만 신경

$$-\sum_{i=1}^N \log P(y_i | x_i; \theta) = -\sum_{i=1}^N y_i^T \cdot \log \hat{y}_i$$

cross entropy loss

평균 네는 건 상식